

DIPLOMADO EN MACHINE LEARNING Y DEEP LEARNING APLICADO · FIUNA

Blindside

Cuánto pedir de cada producto perecedero, en cada tienda, cada día

El problema: pedir algo que vence


Todos los días, cada tienda decide cuánto reponer de cada fresco. Los dos errores cuestan:

- **Pedir de menos:** quiebre de stock y venta perdida
- **Pedir de más:** el sobrante se vence y es pérdida total

Hoy se decide con una regla manual, el **promedio de las últimas semanas**, que no estima incertidumbre.


Y los datos engañan: cuando hubo quiebre, la venta registrada es menor que la demanda.

Costo esperado de una orden (esquema)



La solución planteada

Blindside recomienda una **cantidad a pedir** por tienda × producto, en tres pasos:



1. **Corrige lo que la venta oculta:** estima la demanda de las horas sin stock
2. **Pronostica con incertidumbre:** no un número, un rango calibrado
3. **Traduce el pronóstico a una orden** según el costo de cada error

Cómo sé si funciona: **mejorar al menos 20 %** el error de la referencia y un **intervalo que cubra el 90 %**.


El dataset: FreshRetailNet-50K

Retail de frescos de Dingdong · 50.000 series · 898 tiendas · 18 ciudades · 865 productos · CC BY 4.0

GRUPO	CAMPOS	USO EN BLINDSIDE
Jerarquía	ciudad, tienda, grupo, 3 niveles de categoría, producto	Categóricas del modelo global
Venta	venta diaria y venta por hora (24 valores)	Target y perfil intradiario
Stock	estado por hora (24 valores), horas de quiebre	Detectar y corregir el quiebre
Plan comercial	descuento, feriado, actividad	Covariables conocidas a futuro
Clima	lluvia, temperatura, humedad, viento	Solo con rezago: a 7 días no se conoce

Uso **3.066 series** de 38 tiendas completas: 309 productos, 97 días, 297.402 filas. **43,9 %** de los días tiene al menos una hora de quiebre.

Un día real · serie 812_300 · 26 de mayo



barras: venta por hora · venta registrada del día 14,8
línea: perfil típico de la serie, escalado

Cuando hay quiebre, la venta miente

Si el modelo aprende de la venta registrada, aprende una demanda **artificialmente baja**, y el error se realimenta.

Blindside entrena sobre la **demanda latente estimada**.
Mismo modelo, dos entrenamientos:

Sesgo re-censurado · 0 = ideal

Entrenado sobre
venta observada


-18,19 %

Entrenado sobre
demanda latente

-6,61 %

-20 % -15 % -10 % -5 % 0

Reducción: 11,57 puntos



Qué modelos probé y por qué

MODELO	POR QUÉ ESTÁ EN LA COMPARACIÓN	MASE
Naive estacional	Referencia: repite la semana anterior. Es la vara del objetivo	1,1002
Media móvil 21 días	Es la regla actual de reposición: promedio de las últimas semanas	0,9048
Croston SBA	Diseñado para demanda intermitente , con muchos ceros	0,8952
Ridge	Mismas features que el boosting, pero lineal: mide cuánto aporta la no linealidad	0,9018
SARIMA · Prophet *	Clásicos por serie : ¿el global solo le gana a baselines simples?	0,9136 · 0,9698
LightGBM global	Un modelo para todas las series: cruza calendario, precio, quiebres y jerarquía	0,8222
LightGBM cuantílico + CQR	El servido : se entrena en el cuantil de la orden y calibra el intervalo	0,8217

MASE medio sobre 3.066 series y 8 orígenes. * SARIMA y Prophet sobre 400 series, donde LightGBM da 0,8386.

Un solo modelo global


LightGBM cuantílico global: un modelo aprende de las 3.066 series.

Con 97 días por serie, 3.066 modelos aislados desperdiciarían lo que las series comparten.

Sigue distinguiendo productos: recibe ciudad, tienda, grupo, 3 niveles de categoría y producto como categóricas.

SARIMA empata con la media móvil de 21 días.

Contraste clásico · 400 series · 8 orígenes



barra = media · bigote = ± 1 desvío · | = peor origen

¿Funciona?

25,3 % menos error que la referencia.


MASE **0,8217**

$\pm 0,0454$ · peor origen 0,8790

Objetivo: al menos 20 %.

Cumplido, también en el peor de los 8 orígenes.


3.066 series · 8 orígenes · 7 días ·
1.545.264 predicciones



Cuán seguro está el pronóstico

Para decidir no alcanza un número: hace falta un **rango confiable**.


CQR cubre **88,0 %** con una banda **53 % más angosta** que la alternativa.



Sub-cubre dos puntos: limitación real y declarada.


CQR

88,0 % · ancho 1,805



Conformal de residuos

98,7 % · ancho 3,834



línea punteada = pronóstico · nominal 90 %

De pronóstico a cantidad a pedir


$$q^* = \frac{C_u}{C_u + C_o} = 0,625$$

Distribución predictiva de una serie




El modelo se entrena en q^* : la predicción en ese cuantil **es** la orden.

Toggle medido · 25 series




El producto: qué pedir hoy



Lo que no funcionó también se publica

Clustering como feature

efecto medio +0,28 % de MASE



oscilación entre orígenes $\approx \pm 11$ puntos

Optuna · 25 trials



Series con MASE > 1

404 de 3.066 series · 13,2 %



nivel medio 2,120 vs 1,344

- **Clustering:** no entra al artefacto. Y FreshRetailNet no permite medir arranque en frío: todas las series tienen 97 días
- **Optuna:** la mejora es menor que la dispersión entre orígenes, y el mejor trial dispersa más. No se adopta
- **404 series pierden contra el naive estacional**, y no son las chicas. La interfaz las marca "Modelo no confiable"

Publicar lo que no funcionó es control de sobreajuste, no debilidad.

Qué falta para producción

IMPLEMENTADO	LIMITACIONES	PRÓXIMA VERSIÓN
Recuperación de censura, antifugas, backtesting móvil	97 días de historia · horizonte 7	Ingesta diaria idempotente
LightGBM cuantílico + CQR + newsvendor	Cobertura 88 % vs 90 % nominal; garantía marginal	Candidato, promoción atómica y rollback
SARIMA, Prophet, clustering, Isolation Forest, Optuna	Sin lead time, multi-echelon, mínimos ni cajas	Frescura visible en <code>/health</code>
TreeSHAP · API FastAPI	Sin actualización continua ni drift	Drift y política de reentrenamiento
React 7 pantallas · Streamlit 8 pantallas	Sin autenticación: no exponer públicamente	Datos propios de 12–24 meses
290 tests Python · 41 frontend · 12 Playwright	ROI relativo, no monetario	Restricciones operativas de inventario

Blindside corrige primero lo que la venta oculta, pronostica después y termina en una decisión económica auditable.

Respaldo

Slides A a I para preguntas. No entran en los 15 minutos.

A · Ocho controles antifugas


ASSERT	QUÉ FUGA DETECTA	CASO NEGATIVO INYECTADO
Sin features posteriores a t	Información del día objetivo	Feature que depende del día objetivo
Futuro sin target	Verdad en el índice de futuro	Columna de target en el futuro
Lags agrupados y ordenados	Una serie lee el final de otra	shift sin agrupar
Sin agregados globales	Promedio del panel completo	Media global pegada como feature
Sin target encoding del futuro	Copia del target	Target copiado (correlación $\geq 0,999$)
Escalador ajustado en el fold	Media del panel en el train	Escalador ajustado con todo el panel
Shuffle y alineación	Modelo que no depende del target	Target permutado o corrido un día
Folds disjuntos	Solapamiento train/test	Test que empieza antes del origen

B · Por qué 7 días y no 28

- FreshRetailNet tiene **97 días** por serie
- Con horizonte de 28, caben **como máximo 4 orígenes** de backtest
- La metodología exige **8**
- El split oficial de evaluación tiene exactamente **7 días**

2024-03-28

2024-07-02



8 orígenes móviles · cada uno entrena con lo anterior (gris) y pronostica 7 días (coral)

C · SARIMA fijo vs AutoARIMA

	MASE	TIEMPO POR SERIE
Orden fija	0,9566	85 ms
AutoARIMA	0,9657	2,3 s

La orden fija no perjudicó al contraste: da mejor MASE y es 27 veces más rápida.

D · CQR vs conformal de residuos

$$S_{\text{residuo}} = |y - \hat{y}|$$

$$S_{\text{CQR}} = \max(q_{lo} - y, y - q_{hi})$$

- El score CQR **puede ser negativo**: si los cuantiles ya cubren de más, la calibración **aprieta** el intervalo
- El de residuos absolutos **solo puede ensanchar**
- Resultado: 88,0 % con ancho 1,805 contra 98,7 % con ancho 3,834

E · Recuperación de censura

1. **Perfil horario:** con las horas con stock se estima el perfil de demanda intradiario del día
2. **Peso disponible:** la fracción de la masa diaria que cae en horas con stock
3. **Factor de inflación:** la masa perdida en horas de quiebre se reconstruye a partir de ese peso

Topes conservadores

- Nunca por debajo de la venta observada: la venta ocurrió
- Inflación máxima **×3**
- Sin corrección si queda menos del **15 %** de la masa diaria observable

F · Actualización continua

Hoy: batch. Panel y artefactos se cargan al arrancar la API. Sin ingesta, recarga, drift ni rollback.

Roadmap

ingesta idempotente → candidato → backtest → promoción atómica → observabilidad → drift → rollback

| Un endpoint que reciba un CSV no es actualización continua.

G · Por qué no ampliar FreshRetailNet


- La fuente tiene **90 + 7 días**; las columnas horarias son 24 observaciones **dentro** de cada día
- **Más series sí; más días no**
- Más series no agrega anualidad ni arranque en frío
- Para más tiempo hace falta **otra fuente con 12–24 meses**

H · Literatura y novedad

- **FreshRetailNet-50K** · Dingdong-Inc · arXiv 2505.16319
- **CADRE** · recuperación de demanda sobre el mismo dataset · MDPI Sustainability 18(15):7642
- **Cao 2024** · conformalización del cuantil crítico · arXiv 2412.13159
- Equivalencia entre pronóstico cuantílico calibrado y newsvendor · MDPI JRFM 19(3):173

La contribución no es inventar conformal + newsvendor. Es implementar y evaluar el pipeline completo, con recuperación de censura y decisión operativa.

I · Pipeline y antifugas



— cubierto por los 8 asserts antifugas, cada uno con su fuga inyectada

Los controles encontraron defectos reales:

- `is_censored` del día objetivo entraba como feature
- `days_since_start` tenía otra ancla en inferencia
- Las covariables futuras llegaban como NaN a la API

La ausencia de leakage no se declara: se prueba con tests que fallan.

73 features del artefacto real

Rezagos de demanda	27
Calendario + plan	18
Estadísticos móviles	16
Jerarquía	7
Historial de quiebres	2
Otras	3